

GRAND PRIX '26 • ФИНАЛ • «ИСЧЕЗНУТЬ, ОСТАВИВ УЛЫБКУ»

Полигон **доверия**

Испытание защитных ИИ-агентов результатом и сертификация их права действовать самостоятельно

ЗАКАЗЧИК

АО «Кибериспытание»

КОМАНДА

Пушистики 2: возвращение

«Заказчик научился испытывать **компании** результатом — реализуемо ли недопустимое событие. Мы переносим тот же метод на **защитных ИИ-агентов**».

Защищаться придётся на машинной скорости – а право действовать самостоятельно нельзя выдать тому, чью работу нечем проверить

\$152 · 45 минут

автономный цикл «найти и выпустить патч» на одну уязвимость

ФАКТ · DARPA AIXSS

241 день

средний мировой цикл жизни утечки

БЕНЧМАРК

29% → 9%

готовность полагаться на автономию — падение за год

БЕНЧМАРК

Матрица критериев выбора

КРИТЕРИЙ	ВЕС	УЧЕНИЕ	КОНТУР	ГАРАНТИЯ	ПОЛИГОН
Бьёт в блокер, а не в симптом	6	2	2	1	3
Устойчивость к машинному масштабу	5	2	3	2	3
Скорость запуска в окне 12–18 мес.	4	2	2	3	1
Зависимость от согласия третьих лиц	3	2	1	3	1
Понятность за 10 минут защиты	2	2	2	3	2
Потенциал масштабирования до стандарта	1	2	2	1	3
СУММА БЕЗ ВЕСОВ		12	12	13	13
ВЗВЕШЕННАЯ СУММА		42	44	44	47

ЧЕСТНЫЙ ПРОИГРЫШ

Полигон проигрывает по скорости запуска и зависимости от третьих лиц. Мы выбираем его сознательно: критерий 1 весит вшестеро больше критерия 6.

Краш-тест защитного агента на цифровом двойнике и класс автономии по итогу

UNDERWRITERS LABORATORIES • 1894

Электричество стало массовым не когда стало безопасным, а когда стало страхуемым: появилась независимая лаборатория — и страховщик научился считать тариф.

А

Испытание атакой на двойнике

Сценарии — из корпуса недопустимых событий заказчика.
Результат вместо декларации.

Б

Классы автономии по обратимости

Доверие перестаёт быть бинарным: оно выдаётся частями.

В


Сертификат → ответственность → тариф

Класс перестаёт быть бумагой и становится ценой.

ТИП РЕШЕНИЯ ПО ТЗ

Комбинация: продукт + национальная инфраструктура + регуляторная инициатива.

Не «что установлено», а «реализуемо ли недопустимое событие»



Право на необратимое действие заслуживается на испытании, а не включается по умолчанию

A

Вердикт без действия

Агент оценивает и приоритизирует.
Решает человек.

B

Обратимые действия

Изоляция хоста, блокировка
сессии, карантин файла.

M2 = 0 • ПО ОПРЕДЕЛЕНИЮ

C

Необратимые действия в очерченном контуре

Удаление учётной записи, запись в
продуктив — только в пределах
утверждённых шаблонов.

НЕ ВЫДАЁТСЯ БЕЗ ДОКАЗАННОГО
ДВОЙНИКА

Проверяется не агент, а методика

НОРМАЛЬНЫЙ СЦЕНАРИЙ

М1 выше порога, М2 = 0, класс воспроизвёлся

Присвоен класс В, внесён в реестр. Контрольный случай: методика вообще различает результат.

ПОГРАНИЧНЫЙ СЦЕНАРИЙ

Агент прошёл по метрикам — класс С не выдан

Адекватность двойника не доказана: промышленный сегмент. Потолок — класс В, расхождение зафиксировано в протоколе.

«Полигон, который выдаёт класс всегда, ничего не стоит».

03:40 — агент класса С принял плановое обновление за атаку, удалил техучётку и остановил производственную линию

Ч+0	Ч+0:04	Ч+0:20	Ч+2	Ч+24	Ч+72
ложное необратимое действие, событие уходит в полигон	откат независимым каналом, учётка восстановлена	линия перезапущена, простой посчитан	класс понижен до В автоматически, без ожидания разбора	приостановка класса С у всей линейки вендора	разбор: воспроизводится ли эпизод на двойнике

ЧЕСТНО

Ущерб реальный. Safe harbor его не отменяет — он его распределяет. Мы не превращаем сбой в успех.

САМЫЕ СЛАБЫЕ ЧИСЛА

Ч+24 и Ч+72 первым прогоном не проверяются вовсе — только реальным инцидентом.

Один прогон одного агента за 10 рабочих дней



КРИТЕРИЙ УСПЕХА
Воспроизводимость: повторный прогон того же агента на том же двойнике даёт тот же класс.

ОТРИЦАТЕЛЬНЫЙ ИСХОД
Разные классы означают, что методика не готова. Это результат, а не провал.

685 тыс ₹ → 3 млн ₹

Себестоимость и цена одного испытания. Разрыв закрывает не маржу, а постоянные затраты полигона.

~3%

ожидаемого годового ущерба оператора (100 млн ₹)

~0,6%

страхуемой суммы оператора

≈24,5 млн ₹

выгода оператора в год при переходе на агента класса В

ДОПУЩЕНИЕ

ВЫРУЧКА ТРЕТЬЕГО ГОДА • ТРИ МОДЕЛИ

нижняя граница **310 млн ₹**

базовый **425 млн ₹**

верхняя граница **577 млн ₹**

ФИНАЛЬНЫЙ КРІ

Спред тарифа ≥ 20%

разница в цене полиса для сертифицированных и несертифицированных агентов

Три риска, определяющие запуск

R5 **ВНЕ КОНТРОЛЯ**

Вендоры не подают агентов на испытание

Порог назван: менее 8 вендоров в фазе 2 — EBITDA второго года отрицательна.

Ответ: закрытый первый раунд без публикации низких классов.

R6 **ВНЕ КОНТРОЛЯ**

Safe harbor не проходит законодательный цикл

Ядро опирается на норму, которой в российском праве обнаружить не удалось.

Ответ: старт на договорной конструкции, миграция на закон позже.

R1 **НАША МЕТОДИКА**

Разрыв sim-to-real

Самая высокая цена единичной ошибки: класс C в проде.

Ответ: регламент понижения за 2 часа, приостановка линейки за 24, пересмотр порога за 72.

R5 и R6 вне нашего контроля — говорим прямо: они определяют, состоится ли пилот вообще, а не насколько хорошо он пройдёт.

Шесть разменов, два — вслух

ЧТО ВЫБИРАЕМ		ЧЕМ ЖЕРТВУЕМ
01	Ограниченная автономия по классам: необратимое действие нужно заслужить	Скоростью реакции в классах А и В — частью того преимущества, ради которого всё затевалось
03	Safe harbor, которого в российском праве обнаружить не удалось	Скоростью запуска и юридической прочностью: до НПА защита оператора договорная, а не законная
02	удобство против безопасности — жертвуем охватом	
04	точность двойника — жертвуем числом контуров	
05	непрерывная ре-аттестация — жертвуем стоимостью обслуживания	
06	изоляция контура — жертвуем внешней проверяемостью методики	

Два слабых места, названные прямо

01

Ядро зависит от согласия трёх сторон, которых мы не контролируем: законодателя, вендоров, страховщиков.

02

Разрыв sim-to-real неустраним. Кто сертифицирует сам контрольный слой полигона — открытый вопрос.

7 → 7

атак на логику дали внесённых правок

- 01 мотив вендора → закрытый первый раунд
- 02 safe harbor → запасная договорная конструкция
- 03 монополия арбитра → разделение ролей и апелляция
- 04 экономика → названы пороги ломки, R5 и R4
- 05 окно → старт на договорном safe harbor
- 06 верификатор как узкое место → человек на развилках
- 07 п. 61 приказа № 117 → отдельный контрольный слой

Горизонты по условиям перехода, а не по датам

0-12 мес. Запуск Один двойник, первые классы, договорная конструкция ответственности. Условие перехода: воспроизводимость класса подтверждена на серии прогонов.	12-36 мес. Рынок 3-5 отраслевых двойников, страховой контур на накопленной статистике, апелляции. Условие перехода: страховщик выставил разный тариф сертифицированным и несертифицированным.	36+ мес. Обязательный контур Safe harbor в нормативной форме, классы автономии как признаваемая рамка. Опора: распоряжение № 373-р — ТЭК: ≥100 компаний к 2030, до 500 к 2036.
--	---	--

ОТ АІUC-1

Развели роли испытания, страхования и надзора — его критикуют именно за вертикальную интеграцию.

ОТ КИБЕРПОЛИГОНОВ

Национальный, Standoff, Ampire испытывают людей, мы — агентов. Поэтому они поставщики двойников, а не конкуренты.

Полигон — не ещё одно средство защиты, а условие допуска к автономной защите

«Заказчик научился испытывать компании результатом — реализуемо ли недопустимое событие. Мы переносим тот же метод на защитных ИИ-агентов».

ЧТО ПРОВЕРЕНО

юридический контур по действующим нормам

ЧТО ПРОВЕРЕНО

спрос: вендоры, операторы, государственная траектория

ЧТО ПРОВЕРЕНО

помесячная экономика на три года и точки её ломки

Мы не обещаем, что агент не ошибётся. Мы обещаем, что ошибка будет обратима, посчитана и изменит методику для всех.